

Information Retrieval Models — Vector Space and Probabilistic Approaches

Muhammad Bagus Zulmi (25/572328/PPA/07191)

Vicky Mahfudy (25/573019/PPA/07207)

1 Pendahuluan

Laporan ini membandingkan performa 6 model *ranked retrieval* pada korpus 14.343 dokumen berita berbahasa Indonesia (`News.csv`, kolom `content`): TF, TF-IDF, dan Word2Vec (*TF-IDF weighted*) sebagai model *vector space*; serta Query-Likelihood (QL) tanpa *smoothing*, QL Laplace, dan QL *linear interpolation* ($\lambda = 0,5$) sebagai model probabilistik. Preprocessing yang diterapkan pada semua model: *lowercasing*, penghapusan tanda baca, tokenisasi, dan penghapusan *stopword* Bahasa Indonesia. Kelima query uji yang sama digunakan pada seluruh model, masing-masing mengambil *top-10* dokumen. Kode dan hasil lengkap tersedia di <https://github.com/vickymahfudy/stbi-tugas-1>.

2 Waktu Komputasi

Model	Mean (s)	Std (s)	Min (s)	Max (s)
Word2Vec (TF-IDF weighted)	0,0046	0,0023	0,0029	0,0086
QL (No Smoothing)	0,0087	0,0029	0,0060	0,0136
TF-IDF	0,0130	0,0030	0,0101	0,0171
QL (Laplace)	0,0208	0,0057	0,0148	0,0301
QL (Linear Interpolation)	0,0248	0,0049	0,0163	0,0290
TF	0,0624	0,0084	0,0569	0,0771

Table 1: Rata-rata waktu komputasi per model (5 query, korpus 14.343 dokumen).

Word2Vec paling cepat karena *similarity* dihitung pada ruang vektor berdimensi rendah (100) yang sudah dibangun sebelumnya. QL tanpa *smoothing* juga cepat karena dokumen langsung tereliminasi (skor $-\infty$) begitu satu kata query tidak ditemukan. TF paling lambat karena implementasi `CountVectorizer` tidak melakukan *precomputation* bobot seperti TF-IDF, membuat *transform* dan *cosine similarity* lebih mahal.

3 Relevansi Dokumen Terhadap Query

Sebagai proksi otomatis relevansi digunakan `term_overlap_ratio` (rasio kata query yang muncul literal di dokumen hasil), dirangkum pada Tabel 2.

Model	Mean	Std
QL (No Smoothing)	1,000	0,000
QL (Linear Interpolation)	0,931	0,094
QL (Laplace)	0,909	0,113
TF	0,781	0,190
TF-IDF	0,754	0,203
Word2Vec (TF-IDF weighted)	0,698	0,220

Table 2: Rata-rata proksi relevansi (`term_overlap_ratio`) per model.

Catatan penting: nilai 1,000 pada QL tanpa *smoothing* bukan tanda relevansi terbaik, melainkan artefak mekanisme kerjanya: dokumen yang tidak memuat seluruh kata query otomatis dieliminasi, sehingga yang lolos filter pasti *overlap* penuh, dan *top-10*-nya seringkali tidak terisi penuh akibat *data sparsity*. Sebaliknya, nilai Word2Vec yang paling rendah menandakan model ini menangkap kemiripan semantik, bukan berarti paling tidak relevan. Evaluasi relevansi yang valid membutuhkan penilaian manual terhadap isi dokumen, bukan hanya *overlap* kata literal.

4 Perbandingan Top-10 Antar Model

Jaccard similarity dari himpunan dokumen *top-10* dihitung untuk setiap pasangan model pada masing-masing dari 5 query, lalu dirata-ratakan (Tabel 3).

Pasangan Model	Jaccard (rata-rata)
QL No Smoothing vs QL Linear Interp.	0,579
TF vs QL Linear Interp.	0,271
TF vs TF-IDF	0,251
TF-IDF vs QL Linear Interp.	0,247
TF vs Word2Vec	0,209
QL No Smoothing vs QL Laplace	0,197
TF vs QL No Smoothing	0,172
QL Laplace vs QL Linear Interp.	0,168
TF-IDF vs Word2Vec	0,161
TF-IDF vs QL No Smoothing	0,154
TF vs QL Laplace	0,153
TF-IDF vs QL Laplace	0,153
Word2Vec vs QL Linear Interp.	0,133
Word2Vec vs QL No Smoothing	0,098
Word2Vec vs QL Laplace	0,093

Table 3: Rata-rata *Jaccard similarity* top-10 antar seluruh pasangan model (5 query).

QL tanpa *smoothing* dan QL *linear interpolation* paling mirip (Jaccard 0,579), wajar karena keduanya berbasis probabilitas kata yang sama sebelum *smoothing* diterapkan. Word2Vec konsisten memiliki *overlap* terendah dengan seluruh varian QL (0,09–0,13), mengonfirmasi representasi semantik menangkap relevansi dari sudut pandang berbeda dibanding model probabilistik berbasis kata literal.

5 Kesimpulan

- Tidak ada model yang unggul di semua aspek: Word2Vec paling cepat namun proksi relevansi literal-nya terendah; QL tanpa *smoothing* tampak sempurna pada proksi relevansi hanya karena mekanisme eliminasinya, bukan kualitas retrieval yang sesungguhnya.
- TF-IDF menawarkan keseimbangan yang baik: lebih cepat dari TF, tetap berbasis pencocokan literal yang mudah diinterpretasi.
- *Smoothing* pada QL (Laplace maupun *linear interpolation*) mengatasi eliminasi keras pada QL tanpa *smoothing*, membuat *top-10* lebih konsisten terisi penuh dan toleran terhadap variasi kata.
- Proksi relevansi berbasis *overlap* literal memiliki keterbatasan nyata untuk model semantik dan model dengan eliminasi ketat; evaluasi manual tetap diperlukan untuk klaim relevansi yang valid.

6 Keterbatasan dan Rencana Lanjutan

- Word2Vec masih dilatih *from-scratch* dari korpus, belum menggunakan model *pretrained* Bahasa Indonesia seperti diharapkan pada spesifikasi tugas.
- Task 4 (*enhancement* dengan *stemming* Sastrawi) belum tuntas dieksekusi pada seluruh korpus karena *stemming* murni Python berjalan lambat untuk *vocabulary* berukuran besar; sedang dipertimbangkan pendekatan *caching* hasil *stemming* ke *disk*.
- Evaluasi relevansi manual belum dilakukan secara sistematis; kolom `relevan_manual` pada *file hasil_retrieval.csv* disediakan untuk pekerjaan ini.